作业二

一、实验目的

通过使用 Hadoop MapReduce 和 Spark 框架，实现数据处理的常见任务，包括**数据去重、数据排序、计算平均值和单表关联**，从而加深对分布式计算框架的理解和应用能力。

二、实验环境

- 操作系统：Ubuntu 22.04 LTS
- 虚拟机：UTM
- 集群节点：1 个 master 节点，2 个 slave 节点（slave1, slave2）
- 网络配置：静态 IP 地址
- 软件版本：
  - Hadoop: 2.7.1
  - Spark: 2.2.0
  - Scala：2.11.8

三、hadoop MapReduc任务

3.1 数据去重

3.3.1 代码实现

```
import org.apache.hadoop.fs.Path
import org.apache.hadoop.io.{Text, NullWritable}
import org.apache.hadoop.mapreduce.{Job, Mapper, Reducer}
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat
import org.apache.hadoop.conf.Configuration

object DedupJob {

  // Mapper：直接输出每一行文本作为 key，value 是 NullWritable
  class DedupMapper extends Mapper[Object, Text, Text, NullWritable] {
    private val line = new Text()

    override def map(key: Object, value: Text, context: Mapper[Object, Text, Text,
NullWritable]#Context): Unit = {
      if (value != null && value.toString.trim.nonEmpty) {
        line.set(value.toString.trim)
        context.write(line, NullWritable.get())
      }
    }
  }

```

```scala
  // Reducer：对每个唯一的 key（即原始行文本）只输出一次
  class DedupReducer extends Reducer[Text, NullWritable, Text, NullWritable] {
    override def reduce(key: Text, values: java.lang.Iterable[NullWritable],
                        context: Reducer[Text, NullWritable, Text,
NullWritable]#Context): Unit = {
      // 只输出一次，达到去重目的
      context.write(key, NullWritable.get())
    }
  }

  // 主程序入口
  def main(args: Array[String]): Unit = {
    if (args.length < 2) {
      System.err.println("Usage: DedupJob <input1> [<input2> ...] <output>")
      System.exit(1)
    }

    val conf = new Configuration()
    val job = Job.getInstance(conf, "Scala Hadoop Dedup Job")

    job.setJarByClass(DedupJob.getClass)
    job.setMapperClass(classOf[DedupMapper])
    job.setReducerClass(classOf[DedupReducer])

    job.setOutputKeyClass(classOf[Text])
    job.setOutputValueClass(classOf[NullWritable])

    // 添加所有输入路径
    for (i <- 0 until args.length - 1) {
      FileInputFormat.addInputPath(job, new Path(args(i)))
    }

    // 设置输出路径
    FileOutputFormat.setOutputPath(job, new Path(args.last))

    // 提交作业并退出
    System.exit(if (job.waitForCompletion(true)) 0 else 1)
  }
}
```

3.3.2 实验步骤

1. 在本地创建并编辑文件file1、file2：

```
file1
2012-3-1 a
2012-3-2 b
2012-3-3 c
2012-3-4 d
2012-3-5 a
2012-3-6 b
```

```
2012-3-7 c
2012-3-3 c

file2
2012-3-1 b
2012-3-2 a
2012-3-3 b
2012-3-4 d
2012-3-5 a
2012-3-6 c
2012-3-7 d
2012-3-3 c

# 冗余数据
2012-3-3 c
2012-3-4 d
2012-3-5 a
```

使用命令`hdfs dfs -put file1 file2 \user\lfl\input\dedup`将文件上传到Hadoop集群（**路径内文件夹均已提前创建**），上传成功后通过访问`master:50070`Web页面查看：

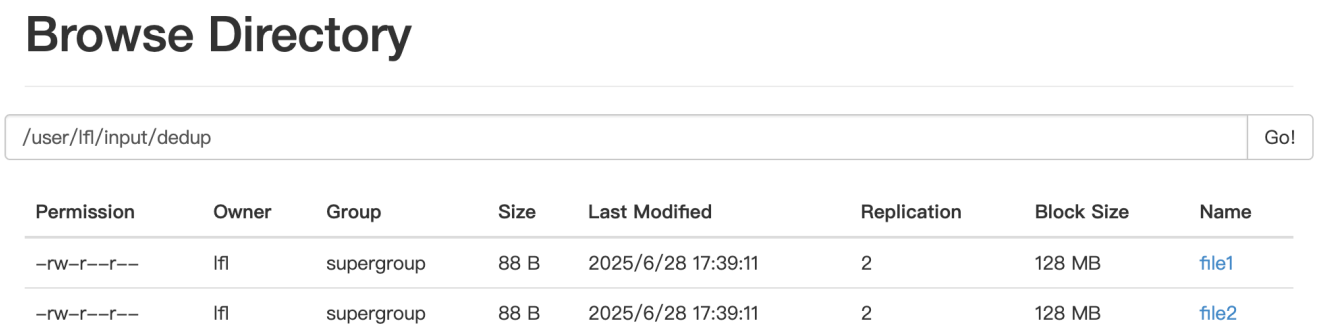

2. 编译打包代码成 JAR 文件

   实验过程已经把所有代码实现，因此四个源文件均一起编译并打包为`MapReduce-assembly-0.1.jar`，提交作业时只需选定相应的类，如下：

```
lfl@master:~/MapReduce$ sbt 'show discoveredMainClasses'
[info] welcome to sbt 1.5.5 (Oracle Corporation Java 1.8.0_151)
[info] loading settings for project mapreduce-build from plugins.sbt ...
[info] loading project definition from /home/lfl/MapReduce/project
[info] loading settings for project mapreduce from build.sbt ...
[info] set current project to MapReduce (in build file:/home/lfl/MapReduce/)
[info] * DedupJob
[info] * SortedIndexJob
[info] * StudentAvgJob
[info] * TableReferJob
[success] Total time: 10 s, completed Jul 4, 2025 4:31:28 PM
```

   后续任务直接在集群上运行作业

3. 在Hadoop集群上运行作业

   在工程根目录下使用命令

```
hadoop jar target/scala-2.11/MapReduce-assembly-0.1.jar DedupJob \
  /user/lfl/input/dedup/file1 \
  /user/lfl/input/dedup/file2 \
  /user/lfl/output/mapreddedup_result
```

3.1.3 实验结果

成功运行后可在Web页面查看输出文件是否存在:

/user/lfl/output/mapreddedup_result Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	0 B	2025/7/4 22:42:41	2	128 MB	_SUCCESS
-rw-r--r--	lfl	supergroup	33 B	2025/7/4 22:42:43	2	128 MB	part-00000
-rw-r--r--	lfl	supergroup	33 B	2025/7/4 22:42:44	2	128 MB	part-00001
-rw-r--r--	lfl	supergroup	33 B	2025/7/4 22:42:44	2	128 MB	part-00002
-rw-r--r--	lfl	supergroup	33 B	2025/7/4 22:42:44	2	128 MB	part-00003

查看并验证输出结果

```
lfl@master:~/MapReduce$ hdfs dfs -cat /user/lfl/output/sparkdedup_result/part*
2012-3-1 a
2012-3-1 b
2012-3-2 a
2012-3-2 b
2012-3-3 b
2012-3-3 c
2012-3-4 d
2012-3-5 a
2012-3-6 b
2012-3-6 c
2012-3-7 c
2012-3-7 d
```

3.2 数据排序

3.2.1 代码实现

```
import org.apache.hadoop.conf.Configuration
import org.apache.hadoop.fs.Path
import org.apache.hadoop.io.{IntWritable, LongWritable, Text}
import org.apache.hadoop.mapreduce.{Job, Mapper, Reducer}
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat

import java.lang.{Long => JLong}
import scala.collection.JavaConverters._

```

```scala
object SortedIndexJob {

  class SortMapper extends Mapper[LongWritable, Text, IntWritable, IntWritable] {
    private val num = new IntWritable()

    override def map(key: LongWritable, value: Text, context: Mapper[LongWritable, Text, IntWritable, IntWritable]#Context): Unit = {
      val line = value.toString.trim
      if (line.nonEmpty) {
        try {
          num.set(line.toInt)
          context.write(num, new IntWritable(1)) // 只使用 key 参与排序
        } catch {
          case _: NumberFormatException => // 忽略非法行
        }
      }
    }
  }

  class SortReducer extends Reducer[IntWritable, IntWritable, Text, IntWritable] {
  private var index = 1
  private val outputKey = new Text()

  override def reduce(key: IntWritable, values: java.lang.Iterable[IntWritable],
                      context: Reducer[IntWritable, IntWritable, Text, IntWritable]#Context): Unit = {
    for (_ <- values.iterator().asScala) {
      outputKey.set(index.toString)
      context.write(outputKey, key)
      index += 1
    }
  }
}

  def main(args: Array[String]): Unit = {
    if (args.length < 2) {
      System.err.println("Usage: SortedIndexJob <input1> [<input2> ...] <output>")
      System.exit(1)
    }

    val conf = new Configuration()
    val job = Job.getInstance(conf, "SortedIndexJob")

    job.setJarByClass(SortedIndexJob.getClass)
    job.setMapperClass(classOf[SortMapper])
    job.setReducerClass(classOf[SortReducer])

    job.setMapOutputKeyClass(classOf[IntWritable])
    job.setMapOutputValueClass(classOf[IntWritable])
    job.setOutputKeyClass(classOf[Text])
    job.setOutputValueClass(classOf[IntWritable])

```

```
61      for (i <- 0 until args.length - 1) {
62        FileInputFormat.addInputPath(job, new Path(args(i)))
63      }
64      FileOutputFormat.setOutputPath(job, new Path(args.last))
65
66      System.exit(if (job.waitForCompletion(true)) 0 else 1)
67    }
68  }
```

3.2.2 实验步骤

1. 准备包含整数数据的输入文件

   在本地创建并编辑文件file3、file4、file5：

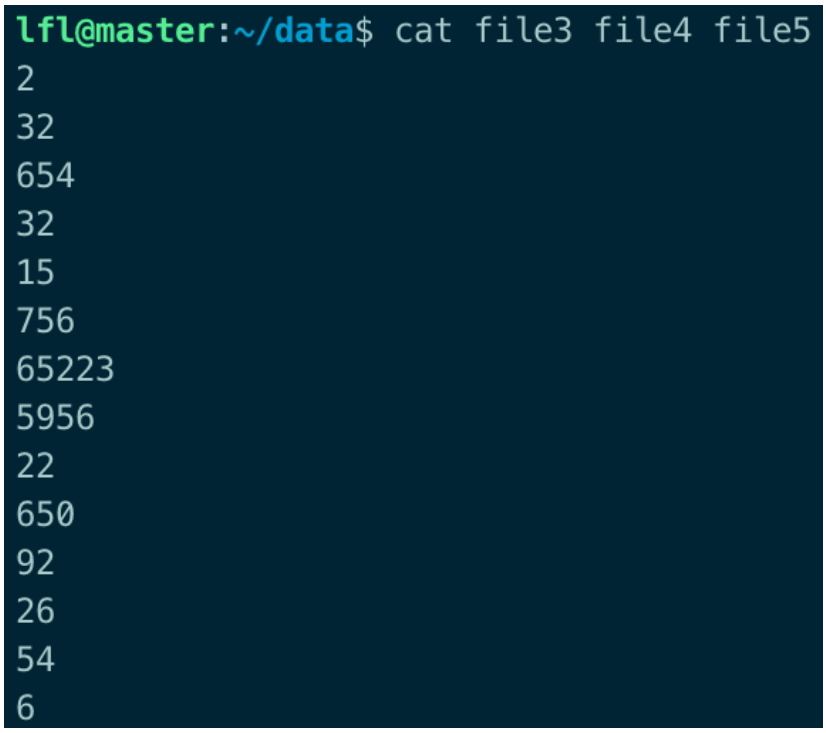

   使用命令`hdfs dfs -put file3 file4 file5 \user\lfl\input\sort`将文件上传到Hadoop集群（**路径内文件夹均已提前创建**），上传成功后通过访问`master:50070`Web页面查看：

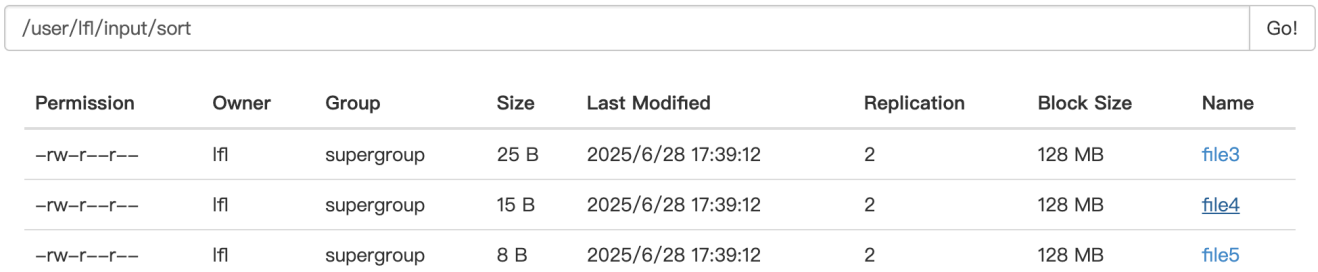

2. 在Hadoop集群上运行作业

   在工程根目录下使用命令

```
hadoop jar target/scala-2.11/MapReduce-assembly-0.1.jar DedupJob \
  /user/lfl/input/sort/file3 \
  /user/lfl/input/sort/file4 \
  /user/lfl/input/sort/file5 \
  /user/lfl/output/mapredsorted_result
```

3.2.3 实验结果

成功运行后可在Web页面查看输出文件是否存在

/user/lfl/output/mapredsorted_result Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	0 B	2025/7/4 22:43:13	2	128 MB	_SUCCESS
-rw-r--r--	lfl	supergroup	23 B	2025/7/4 22:43:15	2	128 MB	part-00000
-rw-r--r--	lfl	supergroup	27 B	2025/7/4 22:43:15	2	128 MB	part-00001
-rw-r--r--	lfl	supergroup	31 B	2025/7/4 22:43:15	2	128 MB	part-00002

查看并验证输出结果

```
lfl@master:~/MapReduce$ hdfs dfs -cat /user/lfl/output/sparksorted_result/part*
1       2
2       6
3       15
4       22
5       26
6       32
7       32
8       54
9       92
10      650
11      654
12      756
13      5956
14      65223
```

可观察到输出文件中的数据按升序排列

3.3 平均

3.3.1 代码实现

```
import org.apache.hadoop.conf.Configuration
import org.apache.hadoop.fs.Path
import org.apache.hadoop.io.{IntWritable, Text}
import org.apache.hadoop.mapreduce.{Job, Mapper, Reducer}
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat
```

```scala

import scala.jdk.CollectionConverters._

object StudentAvgJob {

  // Mapper 输出：key 为学生名，value 为该科成绩
  class AvgMapper extends Mapper[Object, Text, Text, IntWritable] {
    private val name = new Text()
    private val scoreWritable = new IntWritable()

    override def map(key: Object, value: Text, context: Mapper[Object, Text, Text, IntWritable]#Context): Unit = {
      val line = value.toString.trim
      if (line.nonEmpty) {
        val parts = line.split("\\s+")
        if (parts.length == 2) {
          try {
            name.set(parts(0))
            scoreWritable.set(parts(1).toInt)
            context.write(name, scoreWritable)
          } catch {
            case _: NumberFormatException => // 忽略非法数据
          }
        }
      }
    }
  }

  // Reducer 输出：key 为学生名，value 为平均成绩
  class AvgReducer extends Reducer[Text, IntWritable, Text, IntWritable] {
    override def reduce(key: Text, values: java.lang.Iterable[IntWritable],
                        context: Reducer[Text, IntWritable, Text, IntWritable]#Context): Unit = {
      val scores = values.asScala.map(_.get)
      val sum = scores.sum
      val count = scores.size
      val avg = if (count > 0) sum / count else 0
      context.write(key, new IntWritable(avg))
    }
  }

  def main(args: Array[String]): Unit = {
    if (args.length < 2) {
      System.err.println("Usage: StudentAvgJob <input1> [<input2> ...] <output>")
      System.exit(1)
    }

    val conf = new Configuration()
    val job = Job.getInstance(conf, "Scala Hadoop StudentAvgJob")

    job.setJarByClass(this.getClass)
    job.setMapperClass(classOf[AvgMapper])
```

```
    job.setReducerClass(classOf[AvgReducer])

    job.setMapOutputKeyClass(classOf[Text])
    job.setMapOutputValueClass(classOf[IntWritable])
    job.setOutputKeyClass(classOf[Text])
    job.setOutputValueClass(classOf[IntWritable])

    // 多个输入路径
    for (i <- 0 until args.length - 1) {
      FileInputFormat.addInputPath(job, new Path(args(i)))
    }

    // 设置输出路径
    FileOutputFormat.setOutputPath(job, new Path(args.last))

    System.exit(if (job.waitForCompletion(true)) 0 else 1)
  }
}
```

3.3.2 实验步骤

1. 准备包含学生姓名和成绩的数据文件，每行格式为 “姓名 成绩”。

   在本地创建并编辑文件math、chinese、english:

```
# math
张三 88
李四 99
王五 66
赵六 77

#chinese
张三 78
李四 89
王五 96
赵六 67

#english
张三 80
李四 82
王五 84
赵六 86
```

   使用命令`hdfs dfs -put math chinese english \user\lfl\input\average`将文件上传到Hadoop集群（**路径内文件夹均已提前创建**），上传成功后通过访问`master:50070`Web页面查看：

/user/lfl/input/average Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	40 B	2025/7/3 11:23:50	2	128 MB	chinese
-rw-r--r--	lfl	supergroup	40 B	2025/7/3 11:23:50	2	128 MB	english
-rw-r--r--	lfl	supergroup	42 B	2025/7/3 11:23:50	2	128 MB	math

2. 在Hadoop集群上运行作业

   在项目根目录下运行命令

```
hadoop jar target/scala-2.11/MapReduce-assembly-0.1.jar SortedIndexJob \
  /user/lfl/input/sort/math \
  /user/lfl/input/sort/chinese \
  /user/lfl/input/sort/english \
  /user/lfl/output/mapredaverage_result
```

3.3.3 实验结果

运行成功后可在Web页面查看输出文件是否存在：

/user/lfl/output/mapredaverage_result Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	0 B	2025/7/4 22:43:31	2	128 MB	_SUCCESS
-rw-r--r--	lfl	supergroup	20 B	2025/7/4 22:43:33	2	128 MB	part-00000
-rw-r--r--	lfl	supergroup	10 B	2025/7/4 22:43:34	2	128 MB	part-00001
-rw-r--r--	lfl	supergroup	10 B	2025/7/4 22:43:34	2	128 MB	part-00002

查看并验证运行结果：

```
lfl@master:~$ hdfs dfs -cat /user/lfl/output/sparkaverage_result/part*
张三 82
李四 90
王五 82
赵六 76
```

可观察到输出文件中包含每个学生的平均成绩，验证了计算平均功能。

3.4 单表关联

3.4.1 代码实现

```
import org.apache.hadoop.conf.Configuration
import org.apache.hadoop.fs.Path
import org.apache.hadoop.io.{Text}
import org.apache.hadoop.mapreduce.{Job, Mapper, Reducer}
```

```scala
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat

import scala.jdk.CollectionConverters._

object TableReferJob {

  class RelationMapper extends Mapper[Object, Text, Text, Text] {
    override def map(key: Object, value: Text, context: Mapper[Object, Text, Text, Text]#Context): Unit = {
      val line = value.toString.trim
      if (line.nonEmpty && !line.startsWith("child")) { // 跳过表头
        val parts = line.split("\\s+")
        if (parts.length == 2) {
          val child = parts(0)
          val parent = parts(1)
          // 发出 parent -> child
          context.write(new Text(parent), new Text("C:" + child))
          // 发出 child -> parent
          context.write(new Text(child), new Text("P:" + parent))
        }
      }
    }
  }

  class RelationReducer extends Reducer[Text, Text, Text, Text] {
    override def reduce(key: Text, values: java.lang.Iterable[Text],
                        context: Reducer[Text, Text, Text, Text]#Context): Unit = {

      val grandchildren = scala.collection.mutable.ListBuffer[String]()
      val grandparents = scala.collection.mutable.ListBuffer[String]()

      for (v <- values.asScala) {
        if (v.toString.startsWith("C:")) {
          grandchildren += v.toString.substring(2)
        } else if (v.toString.startsWith("P:")) {
          grandparents += v.toString.substring(2)
        }
      }

      for (gc <- grandchildren; gp <- grandparents) {
        context.write(new Text(gc), new Text(gp))
      }
    }
  }

  def main(args: Array[String]): Unit = {
    if (args.length < 2) {
      System.err.println("Usage: TableReferJob <input1> [<input2> ...] <output>")
      System.exit(1)
    }

```

```
    val conf = new Configuration()
    val job = Job.getInstance(conf, "Scala Hadoop TableRefer Job")

    job.setJarByClass(this.getClass)
    job.setMapperClass(classOf[RelationMapper])
    job.setReducerClass(classOf[RelationReducer])

    job.setMapOutputKeyClass(classOf[Text])
    job.setMapOutputValueClass(classOf[Text])
    job.setOutputKeyClass(classOf[Text])
    job.setOutputValueClass(classOf[Text])

    // 添加输入路径
    for (i <- 0 until args.length - 1) {
      FileInputFormat.addInputPath(job, new Path(args(i)))
    }

    // 设置输出路径
    FileOutputFormat.setOutputPath(job, new Path(args.last))

    System.exit(if (job.waitForCompletion(true)) 0 else 1)
  }
}
```

3.4.2 实验步骤

1. 准备包含亲子关系的数据文件，第一行为表头 “child parent”

   在本地创建并编辑文件child-parent:

   ```
   child parent
   Tom Lucy
   Tom Jack
   Jone  Lucy
   Jone  Jack
   Lucy  Mary
   Lucy  Ben
   Jack  Alice
   Jack  Jesse
   Terry Alice
   Terry Jesse
   Philip  Terry
   Philip  Alma
   Mark  Terry
   Mark  Alma
   ```

   使用命令`hdfs dfs -put child-parent \user\lfl\input\tablerefer`将文件上传到Hadoop集群（**路径内文件夹均已提前创建**），上传成功后通过访问`master:50070`Web页面查看：

2. 在spark集群上运行作业

   在项目根目录下运行命令

```
hadoop jar target/scala-2.11/MapReduce-assembly-0.1.jar tablereferJob \
  /user/lfl/input/tablerefer/child-parent \
  /user/lfl/output/mapredtablerefer_result
```

3.4.3 实验结果

运行成功后可在Web页面查看输出文件是否存在：

/user/lfl/output/mapredtablerefer_result Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	0 B	2025/7/4 22:43:51	2	128 MB	_SUCCESS
-rw-r--r--	lfl	supergroup	0 B	2025/7/4 22:43:51	2	128 MB	part-00000
-rw-r--r--	lfl	supergroup	23 B	2025/7/4 22:43:53	2	128 MB	part-00001
-rw-r--r--	lfl	supergroup	48 B	2025/7/4 22:43:53	2	128 MB	part-00002
-rw-r--r--	lfl	supergroup	0 B	2025/7/4 22:43:54	2	128 MB	part-00003
-rw-r--r--	lfl	supergroup	0 B	2025/7/4 22:43:54	2	128 MB	part-00004
-rw-r--r--	lfl	supergroup	78 B	2025/7/4 22:43:54	2	128 MB	part-00005

查看并验证运行结果：

```
lfl@master:~/data$ hdfs dfs -cat /user/lfl/output/sparktablerefer_result/part*
grandchild      grandparent
Philip  Alice
Philip  Jesse
Mark    Alice
Mark    Jesse
Tom     Mary
Tom     Ben
Jone    Mary
Jone    Ben
Tom     Alice
Tom     Jesse
Jone    Alice
Jone    Jesse
```

输出文件中包含每个孙子和祖父母的关系。

四、Spark任务

4.1 数据去重

4.1.1 代码实现

```
import org.apache.spark.{SparkConf, SparkContext}

object SparkDedupJob {
```

```scala
  def main(args: Array[String]): Unit = {
    if (args.length < 2) {
      System.err.println("Usage: DedupApp <input1> [<input2> ... <inputN>] <output>")
      System.exit(1)
    }

    val output = args.last
    val inputPaths = args.slice(0, args.length - 1)

    val conf = new SparkConf().setAppName("DedupApp")
    val sc = new SparkContext(conf)

    val inputRDDs = inputPaths.map(path => sc.textFile(path))
    val mergedRDD = sc.union(inputRDDs)

    val result = mergedRDD.distinct().sortBy(x => x)

    result.saveAsTextFile(output)

    sc.stop()
  }
}
```

4.1.2 实验步骤

1. 准备包含重复数据的输入文件

   在本地创建并编辑文件file1、file2：

```
file1
2012-3-1 a
2012-3-2 b
2012-3-3 c
2012-3-4 d
2012-3-5 a
2012-3-6 b
2012-3-7 c
2012-3-3 c

file2
2012-3-1 b
2012-3-2 a
2012-3-3 b
2012-3-4 d
2012-3-5 a
2012-3-6 c
2012-3-7 d
2012-3-3 c

# 冗余数据
2012-3-3 c
2012-3-4 d
```

```
2012-3-5 a
```

使用命令`hdfs dfs -put file1 file2 \user\lfl\input\dedup`将文件上传到Hadoop集群（**路径内文件夹均已提前创建**），上传成功后通过访问`master:50070`Web页面查看：

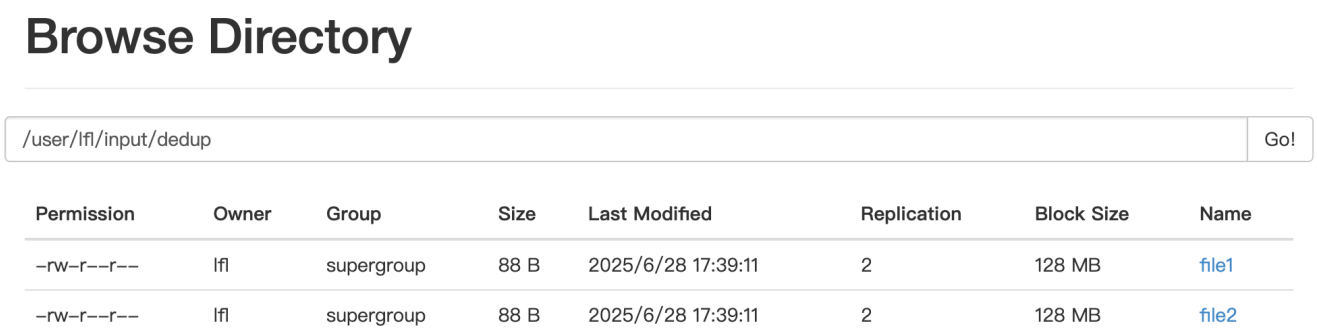

2. 编译打包代码成 JAR 文件

   实验过程已经把所有代码实现，因此四个源文件均一起编译并打包为`sparkjob_2.11-0.1.jar`，提交作业时只需选定相应的类，如下：

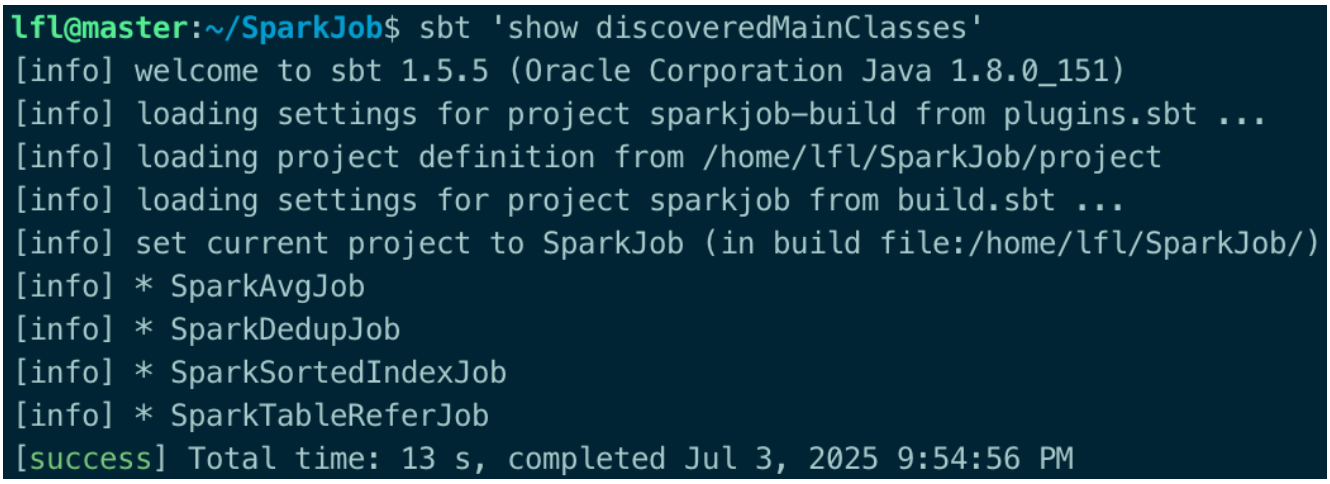

   后续任务直接在集群上运行作业

3. 在spark集群上运行作业

   在工程根目录下使用命令

```
spark-submit \
  --class SparkDedupJob \
  --master spark://master:7077 \
  target/scala-2.11/sparkjob_2.11-0.1.jar \
  hdfs:/user/lfl/input/dedup/file1 \
  hdfs:/user/lfl/input/dedup/file2 \
  hdfs:/user/lfl/output/sparkdedup_result
```

4.1.3 实验结果

成功运行后可在Web页面查看输出文件是否存在

/user/lfl/output/sparkdedup_result Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	0 B	2025/7/3 10:38:22	2	128 MB	_SUCCESS
-rw-r--r--	lfl	supergroup	33 B	2025/7/3 10:38:21	2	128 MB	part-00000
-rw-r--r--	lfl	supergroup	33 B	2025/7/3 10:38:21	2	128 MB	part-00001
-rw-r--r--	lfl	supergroup	33 B	2025/7/3 10:38:21	2	128 MB	part-00002
-rw-r--r--	lfl	supergroup	33 B	2025/7/3 10:38:21	2	128 MB	part-00003

查看并验证输出结果

```
lfl@master:~/MapReduce$ hdfs dfs -cat /user/lfl/output/sparkdedup_result/part*
2012-3-1 a
2012-3-1 b
2012-3-2 a
2012-3-2 b
2012-3-3 b
2012-3-3 c
2012-3-4 d
2012-3-5 a
2012-3-6 b
2012-3-6 c
2012-3-7 c
2012-3-7 d
```

可以看到两个文件的重复数据均已删除，输出文件中只包含去重后的数据

4.2 数据排序

4.1.1 代码实现

```scala
import org.apache.spark.sql.SparkSession

object SparkSortedIndexJob {
  def main(args: Array[String]): Unit = {
    if (args.length < 2) {
      System.err.println("Usage: SparkSortedIndexJob <input1> [<input2> ...] <output>")
      System.exit(1)
    }

    val inputPaths = args.slice(0, args.length - 1)
    val outputPath = args.last

    val spark = SparkSession.builder()
      .appName("Spark Sorted Index Job")
      .getOrCreate()

    val sc = spark.sparkContext
```

```scala

    // 读取多个输入路径并合并
    val inputRDD = sc.textFile(inputPaths.mkString(","))

    // 清理空行并尝试转换为 Int
    val numbersRDD = inputRDD
      .map(_.trim)
      .filter(_.nonEmpty)
      .flatMap(line =>
        try {
          Some(line.toInt)
        } catch {
          case _: NumberFormatException => None
        }
      )

    // 排序并 zip 上从 1 开始的索引
    val sortedIndexedRDD = numbersRDD
      .sortBy(num => num)
      .zipWithIndex()
      .map { case (value, idx) => (idx + 1, value) } // index 从 1 开始

    // 格式化为文本：index \t value
    val outputRDD = sortedIndexedRDD.map { case (index, value) => s"$index\t$value" }

    // 写入输出
    outputRDD.saveAsTextFile(outputPath)

    spark.stop()
  }
}
```

4.2.2 实验步骤

1. 准备包含整数数据的输入文件

   在本地创建并编辑文件file3、file4、file5：

```
lfl@master:~/data$ cat file3 file4 file5
2
32
654
32
15
756
65223
5956
22
650
92
26
54
6
```

使用命令`hdfs dfs -put file3 file4 file5 \user\lfl\input\sort`将文件上传到Hadoop集群（**路径内文件夹均已提前创建**），上传成功后通过访问`master:50070`Web页面查看：

/user/lfl/input/sort Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	25 B	2025/6/28 17:39:12	2	128 MB	file3
-rw-r--r--	lfl	supergroup	15 B	2025/6/28 17:39:12	2	128 MB	file4
-rw-r--r--	lfl	supergroup	8 B	2025/6/28 17:39:12	2	128 MB	file5

2. 在spark集群上运行作业

   在工程根目录下使用命令

```
spark-submit \
  --class SparkSortedIndexJob \
  --master spark://master:7077 \
  target/scala-2.11/sparkjob_2.11-0.1.jar \
  hdfs:/user/lfl/input/sort/file3 \
  hdfs:/user/lfl/input/sort/file4 \
  hdfs:/user/lfl/input/sort/file5 \
  hdfs:/user/lfl/output/sparksorted_result
```

4.2.3 实验结果

运行成功后可在Web页面查看输出文件是否存在：

/user/lfl/output/sparksorted_result Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	0 B	2025/7/3 10:44:23	2	128 MB	_SUCCESS
-rw-r--r--	lfl	supergroup	23 B	2025/7/3 10:44:22	2	128 MB	part-00000
-rw-r--r--	lfl	supergroup	27 B	2025/7/3 10:44:22	2	128 MB	part-00001
-rw-r--r--	lfl	supergroup	31 B	2025/7/3 10:44:22	2	128 MB	part-00002

查看并验证运行结果：

```
lfl@master:~/MapReduce$ hdfs dfs -cat /user/lfl/output/sparksorted_result/part*
1       2
2       6
3       15
4       22
5       26
6       32
7       32
8       54
9       92
10      650
11      654
12      756
13      5956
14      65223
```

可观察到输出文件中的数据按升序排列

4.3 平均

4.3.1 代码实现

```scala
import org.apache.spark.sql.SparkSession

object SparkAvgJob {
  def main(args: Array[String]): Unit = {
    if (args.length < 2) {
      System.err.println("Usage: SparkAvgJob <input1> [<input2> ...] <output>")
      System.exit(1)
    }

    val inputPaths = args.slice(0, args.length - 1)
    val outputPath = args.last

    val spark = SparkSession.builder()
      .appName("SparkAvgJob")
      .getOrCreate()

    val sc = spark.sparkContext
```

```
18
19      val inputRDD = sc.textFile(inputPaths.mkString(","))
20
21      val cleanedRDD = inputRDD
22        .map(_.replaceAll("[\\u00A0\\u2000-\\u200B\\u3000\\uFEFF]", " "))
    // 替换全角空格
23        .map(_.replaceAll("\\s+", " ").trim)            // 替换多个空格或 tab 为一个空格
24        .filter(_.nonEmpty)
25
26      val parsed = cleanedRDD.flatMap { line =>
27        val parts = line.split(" ")
28        if (parts.length == 2) {
29          try Some((parts(0), parts(1).toInt)) catch {
30            case _: NumberFormatException => None
31          }
32        } else None
33      }
34
35      val averageByStudent = parsed
36        .mapValues(score => (score, 1))  // (name, (score, 1))
37        .reduceByKey { case ((s1, c1), (s2, c2)) => (s1 + s2, c1 + c2) }
38        .mapValues { case (sum, count) => sum / count } // 取整平均
39
40      val outputRDD = averageByStudent
41        .sortByKey() // 可选：按姓名排序输出
42        .map { case (name, avg) => s"$name $avg" }
43
44      outputRDD.saveAsTextFile(outputPath)
45
46      spark.stop()
47    }
48  }
```

4.3.2 实验步骤

1. 准备包含学生姓名和成绩的数据文件，每行格式为 “姓名 成绩”。

   在本地创建并编辑文件math、chinese、english:

```
1  # math
2  张三 88
3  李四 99
4  王五 66
5  赵六 77
6
7  #chinese
8  张三 78
9  李四 89
10 王五 96
11 赵六 67
12
13 #english
```

```
张三 80
李四 82
王五 84
赵六 86
```

使用命令`hdfs dfs -put math chinese english \user\lfl\input\average`将文件上传到Hadoop集群（**路径内文件夹均已提前创建**），上传成功后通过访问`master:50070`Web页面查看：

/user/lfl/input/average Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	40 B	2025/7/3 11:23:50	2	128 MB	chinese
-rw-r--r--	lfl	supergroup	40 B	2025/7/3 11:23:50	2	128 MB	english
-rw-r--r--	lfl	supergroup	42 B	2025/7/3 11:23:50	2	128 MB	math

2. 在spark集群上运行作业

   在项目根目录下运行命令

```
spark-submit \
  --class SparkAvgJob \
  --master spark://master:7077 \
  target/scala-2.11/sparkjob_2.11-0.1.jar \
  hdfs:/user/lfl/input/average/math \
  hdfs:/user/lfl/input/average/chinese \
  hdfs:/user/lfl/input/average/english \
  hdfs:/user/lfl/output/sparkaverage_result
```

4.3.3 实验结果

运行成功后可在Web页面查看输出文件是否存在：

/user/lfl/output/sparkaverage_result Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	0 B	2025/7/3 11:55:13	2	128 MB	_SUCCESS
-rw-r--r--	lfl	supergroup	20 B	2025/7/3 11:55:11	2	128 MB	part-00000
-rw-r--r--	lfl	supergroup	10 B	2025/7/3 11:55:10	2	128 MB	part-00001
-rw-r--r--	lfl	supergroup	10 B	2025/7/3 11:55:11	2	128 MB	part-00002

查看并验证运行结果：

```
lfl@master:~$ hdfs dfs -cat /user/lfl/output/sparkaverage_result/part*
张三 82
李四 90
王五 82
赵六 76
```

可观察到输出文件中包含每个学生的平均成绩，验证了计算平均功能。

4.4 单表关联

4.4.1 代码实现

```scala
import org.apache.spark.{SparkConf, SparkContext}

object SparkTableReferJob {
  def main(args: Array[String]): Unit = {
    if (args.length != 2) {
      System.err.println("Usage: SparkTableReferJob <input> <output>")
      System.exit(1)
    }

    val inputPath = args(0)
    val outputPath = args(1)

    val conf = new SparkConf().setAppName("SparkTableReferJob")
    val sc = new SparkContext(conf)

    // 读取数据并过滤表头
    val lines = sc.textFile(inputPath)
      .filter(line => !line.trim.startsWith("child"))

    // 拆分为 (child, parent)
    val relations = lines.map(_.trim.split("\\s+")).map {
      case Array(child, parent) => (child, parent)
    }

    // 模拟左表：key = parent, value = "L_child"
    val left = relations.map { case (child, parent) => (parent, "L_" + child) }

    // 模拟右表：key = child, value = "R_parent"
    val right = relations.map { case (child, parent) => (child, "R_" + parent) }

    // 合并并按 key 分组
    val joined = left.union(right).groupByKey()

    // Reduce 阶段做自连接：分开左右表并做笛卡尔积
    val grandchildGrandparent = joined.flatMap {
      case (_, values) =>
        val (leftValues, rightValues) = values.partition(_.startsWith("L_"))
        val grandchildren = leftValues.map(_.substring(2))
        val grandparents = rightValues.map(_.substring(2))
        for {
          gc <- grandchildren
          gp <- grandparents
        } yield (gc, gp)
    }

```

```
    // 添加表头并保存为文本
    val header = sc.parallelize(Seq("grandchild\tgrandparent"))
    val results = grandchildGrandparent.map { case (gc, gp) => s"$gc\t$gp" }

    header.union(results).saveAsTextFile(outputPath)

    sc.stop()
  }
}
```

4.4.2 实验步骤

1. 准备包含亲子关系的数据文件，第一行为表头 “child parent”

   在本地创建并编辑文件child-parent:

   ```
   child parent
   Tom Lucy
   Tom Jack
   Jone  Lucy
   Jone  Jack
   Lucy  Mary
   Lucy  Ben
   Jack  Alice
   Jack  Jesse
   Terry Alice
   Terry Jesse
   Philip  Terry
   Philip  Alma
   Mark  Terry
   Mark  Alma
   ```

   使用命令`hdfs dfs -put child-parent \user\lfl\input\tablerefer`将文件上传到Hadoop集群（**路径内文件夹均已提前创建**），上传成功后通过访问`master:50070`Web页面查看：

2. 在spark集群上运行作业

   在项目根目录下运行命令

   ```
   spark-submit \
     --class SparkTableReferJob \
     --master spark://master:7077 \
     target/scala-2.11/sparkjob_2.11-0.1.jar \
     hdfs:/user/lfl/input/tablerefer/child-parent \
     hdfs:/user/lfl/output/sparktablerefer_result
   ```

4.4.3 实验结果

运行成功后可在Web页面查看输出文件是否存在：

/user/lfl/output/sparktablerefer_result Go!

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	lfl	supergroup	0 B	2025/7/3 17:16:50	2	128 MB	_SUCCESS
-rw-r--r--	lfl	supergroup	0 B	2025/7/3 17:16:47	2	128 MB	part-00000
-rw-r--r--	lfl	supergroup	23 B	2025/7/3 17:16:48	2	128 MB	part-00001
-rw-r--r--	lfl	supergroup	48 B	2025/7/3 17:16:48	2	128 MB	part-00002
-rw-r--r--	lfl	supergroup	0 B	2025/7/3 17:16:45	2	128 MB	part-00003
-rw-r--r--	lfl	supergroup	0 B	2025/7/3 17:16:45	2	128 MB	part-00004
-rw-r--r--	lfl	supergroup	78 B	2025/7/3 17:16:48	2	128 MB	part-00005

查看并验证运行结果：

```
lfl@master:~/data$ hdfs dfs -cat /user/lfl/output/sparktablerefer_result/part*
grandchild      grandparent
Philip  Alice
Philip  Jesse
Mark    Alice
Mark    Jesse
Tom     Mary
Tom     Ben
Jone    Mary
Jone    Ben
Tom     Alice
Tom     Jesse
Jone    Alice
Jone    Jesse
```

输出文件中包含每个孙子和祖父母的关系。

五、遇到的问题及解决方案

5.1 任务运行时slave节点的NodeManager进程终止

- **问题描述**：在Reduce任务的copy拉去阶段时slave节点的NodeManager进程终止，查看日志后发现：

```
2025-07-02 21:17:06,991 WARN org.apache.hadoop.yarn.server.nodemanager.containermanager.monitor.ContainersMonitorImpl: NodeManager configured with 8 G physical memory allocated to containers, which is more than 80% of the total physical memory available (3.8 G). Thrashing might happen.
2025-07-03 11:57:48,828 ERROR org.apache.hadoop.yarn.server.nodemanager.NodeManager: RECEIVED SIGNAL 15: SIGTERM
```

- **解决方案**：目前认为的可能原因是内存溢出，导致ResourceManager终止了NodeManager进程，通过修改`yarn-site.xml`文件配置：

```
<property>
    <name>yarn.nodemanager.resource.memory-mb</name>
    <value>3072</value> <!-- 3GB 内存 -->
</property>
<property>
    <name>yarn.nodemanager.resource.cpu-vcores</name>
    <value>2</value> <!-- CPU核心数 2 -->
</property>
```

五、实验总结

通过本次实验，我成功使用 Hadoop MapReduce 和 Spark 框架实现了数据去重、数据排序、计算平均值和单表关联等常见数据处理任务。在实验过程中，深入理解了分布式计算框架的工作原理和编程模型，同时也掌握了在 Hadoop 集群和 Spark 系统上运行作业的方法。

在 Hadoop MapReduce 任务中，需要手动编写 Mapper 和 Reducer 类，对数据进行处理和聚合，代码相对复杂，但能够更好地控制数据处理的细节。而在 Spark 任务中，使用 RDD 和 DataFrame 等高级抽象，代码更加简洁，开发效率更高。

对比两种框架，Hadoop MapReduce 更适合处理大规模批处理任务，其编程模型虽然繁琐，但具有良好的容错性和稳定性；Spark 则在处理速度和灵活性上更具优势，尤其适合迭代计算和实时数据处理场景，其 DAG 执行引擎能显著提升复杂任务的执行效率。

通过本次实验，我的分布式系统开发能力得到了显著提升，不仅掌握了 Hadoop 和 Spark 的核心编程模型，还学会了如何在集群环境中部署和调试应用程序。同时，也对分布式计算的优势和挑战有了更深入的理解，为今后进一步学习和应用大数据技术奠定了坚实的基础。在未来的学习和工作中，我将继续探索更多大数据处理技术和框架，不断提升自己的专业技能。